

图像分类代表方法扩展综述

DenseNet、ConvNeXt、ConvNeXt V2、EVA

摘要

本文围绕 DenseNet、ConvNeXt、ConvNeXt V2 与 EVA 四个图像分类方法展开。这四种方法可以构成一条清晰的发展线索：早期 CNN 侧重通过连接结构改善梯度传播与特征复用；Transformer 兴起后，ConvNeXt 重新审视卷积网络，并证明纯卷积模型通过现代化设计仍具备强竞争力；ConvNeXt V2 进一步将卷积结构与掩码自监督预训练共同设计；EVA 则把图像分类从“训练一个分类器”推进到“学习可迁移视觉表征/视觉基础模型”的阶段。本文重点分析每种方法的提出背景、核心机制、优缺点和适用场景，并在最后总结图像分类方法从结构创新走向预训练范式创新的发展主线。

目录

- 1. 引言
- 2. 四种方法概览
- 3. DenseNet：CNN 时代的特征复用与梯度传播
- 4. ConvNeXt：Transformer 时代的现代化卷积网络
- 5. ConvNeXt V2：卷积网络与掩码自监督预训练的共同设计
- 6. EVA：面向大规模视觉表征的国产视觉基础模型路线
- 7. 图像分类方法的发展主线
- 8. 参考文献

1. 引言

这四种方法覆盖了图像分类方法近十年中几个重要转折：从 CNN 内部结构优化，到 CNN 与 Transformer 设计思想的融合，再到自监督/基础模型时代的视觉表征学习。

DenseNet 关心深层 CNN 如何更好地传递特征和梯度；ConvNeXt 关心卷积网络如何在 Transformer 的 ViT/Swin 时代重新获得竞争力；ConvNeXt V2 关心卷积网络如何适配 MAE 式自监督预训练；EVA 则关心如何利用大规模 MIM（Masked Image Modeling，掩码图像建模）与语言对齐特征构建强视觉表征。

2. 四种方法概览

方法	年份/阶段	主要贡献	与图像分类的关系
DenseNet	2017 CVPR 经典 CNN 深度化阶段	用密集连接强化特征 复用与梯度传播	直接作为分类 backbone，影响后续多任务骨干设计

ConvNeXt	2022 CVPR ViT 冲击后的 CNN 复兴	从 ResNet 出发现代化改造纯卷积网络	证明 CNN 仍可在 ImageNet 分类和迁移任务中竞争
ConvNeXt V2	2023 CVPR 架构与自监督共设计	为 ConvNeXt 设计全卷积 MAE 与 GRN	让纯 CNN 更好适配 masked pretraining，再用于分类
EVA / EVA-02	2023 CVPR 大规模视觉表征与国产基础模型	用语言对齐视觉特征作为重建目标训练强 ViT 表征	ImageNet 微调和 zero-shot 分类表现突出

3. DenseNet：CNN 时代的特征复用与梯度传播

3.1 提出背景

DenseNet 出现在深层 CNN 快速发展的阶段。ResNet 已经证明，残差连接可以显著缓解深层网络退化和梯度消失问题；DenseNet 则沿着“短路径连接”继续推进，提出更激进的密集连接：每一层都直接接收此前所有层的特征图，并将自己的输出传给后续所有层。

这种设计的核心动机是：深层网络中的不同层并不一定要重复学习相似特征，浅层的边缘、纹理，中层的局部部件，深层的语义模式，都可以被后续层复用。

3.2 核心思想与结构机制

DenseNet 的基本公式可以写为： $x_l = H_l([x_0, x_1, \dots, x_{l-1}])$ 。其中 $[\cdot]$ 表示在通道维度上的拼接， H_l 通常由 BN、ReLU 和卷积组成。这与 ResNet 的加法残差不同：ResNet 是将输入与变换结果相加，DenseNet 则是把历史特征全部保留下来并拼接。

DenseNet 由 Dense Block 和 Transition Layer 组成。Dense Block 内部执行密集连接；Transition Layer 用 1×1 卷积和池化降低通道数与空间分辨率，以控制计算量和显存开销。为了进一步减少参数量，DenseNet 常采用 bottleneck 结构，即先用 1×1 卷积压缩通道，再用 3×3 卷积提取局部特征。

每一层新增的特征通道数为 growth rate。growth rate 越大，表达能力越强，但显存和计算开销也越高；growth rate 较小时，模型更紧凑，更能体现 DenseNet 的参数效率。

3.3 优点

- 特征复用充分：后续层可以直接访问前面所有层的特征，减少重复学习，提高参数利用率。
- 梯度传播路径短：损失信号可以通过密集连接更直接地传向浅层，缓解梯度消失。
- 参数效率较高：由于每层只需产生少量新增特征，DenseNet 在较少参数下也能获得强性能。

3.4 局限

- 显存访问成本较高：大量特征拼接会增加中间激活存储，训练时显存压力明显。
- 推理速度不一定理想：参数少不等于速度快，密集拼接和小层级操作可能降低硬件利用率。
- 大规模预训练时代的扩展性有限：相比 ResNet、ConvNeXt、ViT，DenseNet 较少成为现代大规模视觉基础模型的默认骨干。
- 工程部署复杂度略高：密集连接导致特征依赖关系复杂，对内存布局和推理框架优化不够友好。

3.5 评价与适用场景

DenseNet 是“CNN 结构连接创新”的代表。它不是当前最热门的视觉基础模型骨干，但它说明了特征流动方式、梯度路径长度和特征复用效率的重要性。

在实际应用中，DenseNet 仍常见于中小规模图像分类、医学影像、遥感影像等对参数效率和特征复用较敏感的场景。但如果目标是高吞吐部署或大规模预训练，通常会优先考虑 ResNet、EfficientNet、ConvNeXt 或 ViT 系列。

4. ConvNeXt: Transformer 时代的现代化卷积网络

4.1 提出背景

ViT 和 Swin Transformer 的出现改变了图像分类 backbone 的讨论方式。很多研究者一度认为 Transformer 在视觉任务上的优势来自自注意力机制本身，但 ConvNeXt 提出一个反向问题：如果把传统 ResNet 用 2020 年代的训练策略和结构细节重新设计，纯卷积网络是否仍然可以与 Transformer 竞争？

ConvNeXt 的贡献是系统性地“现代化”了 ResNet。它吸收了视觉 Transformer 的若干有效设计，如更大的感受野、更少的归一化与激活、更合理的阶段比例、更强的训练 recipe，但仍保持纯卷积骨干的工程简洁性。

4.2 核心设计

ConvNeXt 可以理解为从 ResNet 向 Swin/ViT 风格逐步靠近，但不引入自注意力。典型设计包括：

- Patchify stem: 用较大步幅卷积完成早期下采样，使输入处理方式更接近 ViT/Swin 的 patch embedding。
- Stage compute ratio 调整: 重新分配不同阶段的 block 数，使网络计算分布更接近分层 Transformer。
- 大 kernel depthwise convolution: 使用 7×7 depthwise convolution 扩大局部感受野，同时控制参数和 FLOPs。
- 倒瓶颈结构: 先扩展通道再压缩，类似 Transformer MLP 中的通道扩展。
- LayerNorm 与 GELU: 减少传统 BN/ReLU 组合，采用更接近 Transformer 的归一化和激活设计。
- 更简洁的 block: 减少不必要的激活和归一化位置，使模型更接近现代深度网络的简洁设计。

这些设计共同表明，ConvNeXt 是“被 Transformer 经验反向改造后的 CNN”。它仍然依靠卷积归纳偏置处理局部空间结构，但在宏观结构、训练方式和模块细节上已经与传统 ResNet 明显不同。

4.3 优点

- 证明纯 CNN 仍具竞争力: ConvNeXt 在 ImageNet 分类以及 COCO 检测、ADE20K 分割等迁移任务上表现强。
- 工程实现相对简单: 相比 Transformer 的注意力算子，标准卷积生态成熟，部署和推理优化更直接。
- 继承卷积归纳偏置: 对中小数据、局部纹理、空间平移等视觉特征具有天然优势。

4.4 局限

- 长程依赖建模仍不如自注意力直接：大卷积核和层堆叠可以扩大感受野，但并不等价于全局 attention。
- 性能与训练 recipe 高度绑定：很多收益来自强数据增强、优化器、正则化和长训练。
- 开放词表和多模态统一性不如 ViT：CLIP、DINO、EVA 等大规模表征模型通常更偏向 ViT 生态。

4.5 评价与适用场景

ConvNeXt 的价值在于，打破了“Transformer 一定天然优于 CNN”的简单叙事。它说明视觉模型的竞争力来自架构、训练 recipe、数据规模和工程实现的共同作用。对于图像分类任务，获得了接近 Transformer 的性能，同时保留卷积网络的实现简洁性。

5. ConvNeXt V2：卷积网络与掩码自监督预训练的共同设计

5.1 提出背景

2021 年后，视觉模型的竞争重点逐渐从“监督训练下的分类精度”转向“如何利用海量无标注数据进行预训练”。MAE 证明了 masked image modeling 对 ViT 非常有效，但将 MAE 直接套到 ConvNeXt 上并不理想。ConvNeXt V2 正是在这一问题下提出的：卷积网络也需要与自监督预训练方式共同设计。

因此，ConvNeXt V2 把 CNN 结构改进与 masked autoencoder 预训练绑定起来，使纯卷积骨干也能更好享受自监督预训练带来的表征收益。

5.2 核心机制：FCMAE 与 GRN

ConvNeXt V2 提出 Fully Convolutional Masked Autoencoder (FCMAE)。与 ViT-MAE 直接处理 patch token 不同，FCMAE 需要适应卷积网络的特征图结构，并通过稀疏卷积等机制避免在 mask 区域进行无效计算。这样，卷积骨干可以在 masked pretraining 中只处理可见区域，同时保持卷积式层级特征表达。

另一项关键设计是 Global Response Normalization (GRN)。作者观察到，ConvNeXt 与 MAE 式训练结合时容易出现 feature collapse：一些通道响应消失或饱和，通道之间缺少有效竞争。GRN 通过对全局特征响应进行归一化和校准，增强通道之间的对比与竞争，改善表示多样性。

FCMAE 解决的是“卷积网络如何做掩码预训练”，GRN 解决的是“卷积特征在这种预训练下如何避免塌缩”。二者共同构成 ConvNeXt V2 的核心。

5.3 优点

- 把自监督预训练收益带回纯 CNN：ConvNeXt V2 说明 卷积网络也可以通过重新设计适配 MAE。
- 模型尺寸覆盖丰富：既有轻量模型，也有大规模高性能模型，便于不同算力场景选择。
- GRN 具有模块价值：GRN 不仅服务于 ConvNeXt V2，也体现了通道竞争和特征多样性在自监督预训练中的重要性。
- 分类与迁移兼顾：不仅可用于 ImageNet 分类，也可迁移到检测、分割等下游任务。

5.4 局限

- 预训练成本高：虽然是卷积体系，但完整 **masked pretraining** 仍依赖大量数据和算力。
- 生态规模不如 ViT-MAE：ViT 在自监督、多模态和基础模型领域拥有更强统一接口。
- 对小项目未必必要：如果只有小数据集和有限算力，直接使用监督预训练权重微调可能更实际。

5.5 评价与适用场景

ConvNeXt V2 将图像分类方法从“监督学习下的 **backbone** 设计”推进到“**backbone** 与预训练范式共同设计”。实际使用时，ConvNeXt V2 适合希望保留 CNN 工程优势，同时利用自监督预训练提升分类和迁移能力的场景，处于现代 CNN 和后来的视觉基础模型之间。

6. EVA：面向大规模视觉表征的国产视觉基础模型路线

6.1 提出背景

EVA 系列是国内团队在大规模视觉表征与视觉基础模型方向的重要代表。EVA 尤其强调 **masked visual representation learning at scale**。EVA-01 探索大规模掩码视觉表征学习，EVA-02 则进一步提出通过重建语言对齐的视觉特征来训练高性能视觉 Transformer。

在图像分类语境下，EVA 的意义不只是提供一个更强的分类模型，而是展示了大规模预训练、CLIP teacher、MIM 目标和 ViT 架构共同作用下，视觉表征可以获得很强的微调和 **zero-shot** 能力。

6.2 核心机制

EVA-02 的核心是：不直接重建原始像素，而是重建来自强大 CLIP 视觉编码器的语言对齐视觉特征。这样，**masked image modeling** 的目标从低层像素恢复转向更语义化的特征恢复，使预训练过程更接近下游识别和视觉语言理解需要。

EVA-02 仍然基于 plain Vision Transformer，但结合了更新的网络与训练设计，使模型在较少参数和公开数据条件下取得很高性能。它既可以作为图像分类微调 **backbone**，也可以通过 EVA-CLIP 路线参与 **zero-shot** 图像分类和图文对齐任务。

6.3 优点

- 预训练目标更语义化：通过重建语言对齐视觉特征，避免仅像素重建可能带来的语义不足。
- 分类性能强：EVA-02 在 ImageNet 微调与 EVA-CLIP **zero-shot** 分类中都具有代表性表现。
- 兼具视觉与多模态潜力：既能服务纯视觉分类，也能扩展到视觉语言对齐和开放类别识别。

6.4 局限

- 训练体系复杂：性能依赖强 teacher、MIM 训练、大规模数据和细致优化。
- 复现成本高：完整预训练对算力和数据管线要求较高，普通项目更适合直接使用预训练权重。
- 方法更像系统工程：EVA 的强性能来自预训练目标、数据、模型规模和优化 **recipe** 的组合，不易归因到单一模块。

6.5 评价与适用场景

EVA 强调 MIM 与语言对齐视觉特征重建，说明图像分类已从单一监督任务扩展为视觉表征质量的评测入口。

7. 图像分类方法的发展主线

7.1 第一阶段：CNN 内部结构优化——从堆深到特征流动

早期深度 CNN 的关键问题是如何训练更深、更有效的网络。ResNet 用残差连接解决退化问题，DenseNet 则用密集连接进一步强化特征传播和特征复用。这个阶段的核心是结构设计：如何连接层、如何控制参数、如何让梯度更顺畅地流动。

DenseNet 代表了这一阶段的典型思路：网络并不是越深越好，重要的是让每一层都能利用前面已经学到的特征。图像分类在这个阶段主要仍是监督学习框架下的封闭类别分类，ImageNet 精度是最核心指标。

7.2 第二阶段：Transformer 冲击后的 CNN 现代化

ViT 和 Swin 证明 Transformer 可以成为视觉 backbone 后，研究社区开始重新审视 CNN 的局限。但 ConvNeXt 表明，许多所谓 Transformer 的优势并不完全来自 self-attention，而是来自现代训练策略、模型尺度、归一化方式、激活函数和宏观结构设计。

因此，ConvNeXt 的历史意义在于：它让 CNN 从“传统架构”变成“现代架构”。图像分类方法的讨论也从单一算子优劣，转向整体设计空间的比较。

7.3 第三阶段：架构与预训练范式共同设计

当 MAE、CLIP、DINO 等预训练方法兴起后，图像分类不再只依赖人工标注数据上的端到端训练。模型能否利用无标注数据、图文数据或 teacher 特征进行预训练，成为决定最终分类和迁移效果的重要因素。

ConvNeXt V2 是这一阶段的代表：它不是单纯换网络结构，而是针对 masked autoencoder 重新设计卷积预训练流程，并用 GRN 解决特征塌缩问题。这说明图像分类方法的竞争已经从“backbone 本身”扩展到“backbone + pretraining objective + recipe”。

7.4 第四阶段：从分类模型到视觉基础模型

EVA 标志着图像分类进入视觉基础模型阶段。此时，分类准确率仍重要，但它更像是评估视觉表征质量的一个窗口。一个强视觉模型不仅要能在 ImageNet 上分类，还要能迁移到检测、分割、深度估计、检索、开放类别识别甚至多模态任务。

EVA 说明 masked visual representation learning 可以借助语言对齐视觉特征进一步提升语义表达，把图像分类从“封闭类别监督训练”推进到“通用视觉表征学习”。

7.6 主线图谱

阶段	代表方法	核心问题	解决方式	方法重心变化
CNN 深度化	DenseNet	深层网络如何训练、如何复用特征	密集连接、特征拼接、growth rate	从堆深度转向优化特征流动
现代 CNN	ConvNeXt	CNN 是否被 Transformer 淘汰	吸收 ViT/Swin 设计，现代化 ResNet	从传统卷积转向现代化骨干
自监督共设计	ConvNeXt V2	卷积如何适配 MAE 预训练	FCMAE + GRN	从监督分类转向预训练适配
视觉基础模型	EVA	如何通过 MIM 与语言对齐提升视觉表征	重建 CLIP 视觉特征，扩展 ViT 表征	从视觉分类转向视觉/多模态基础模型

8. 参考文献

1. @misc{huang2018denselyconnectedconvolutionalnetworks, title={Densely Connected Convolutional Networks}, author={Gao Huang and Zhuang Liu and Laurens van der Maaten and Kilian Q. Weinberger}, year={2018}, eprint={1608.06993}, archivePrefix={arXiv}, primaryClass={cs.CV}, url={https://arxiv.org/abs/1608.06993}, }

2. @misc{liu2022convnet2020s, title={A ConvNet for the 2020s}, author={Zhuang Liu and Hanzi Mao and Chao-Yuan Wu and Christoph Feichtenhofer and Trevor Darrell and Saining Xie}, year={2022}, eprint={2201.03545}, archivePrefix={arXiv}, primaryClass={cs.CV}, url={https://arxiv.org/abs/2201.03545}, }

3. @misc{woo2023convnextv2codesigningscaling,

title={ConvNeXt V2: Co-designing and Scaling ConvNets with Masked Autoencoders},

author={Sanghyun Woo and Shoubhik Debnath and Ronghang Hu and Xinlei Chen and Zhuang Liu and In So Kweon and Saining Xie},

year={2023},

eprint={2301.00808},

archivePrefix={arXiv},

primaryClass={cs.CV},

url={https://arxiv.org/abs/2301.00808},

}

4. @misc{fang2022evaexploringlimitmasked,

title={EVA: Exploring the Limits of Masked Visual Representation Learning at Scale},

author={Yuxin Fang and Wen Wang and Binhui Xie and Quan Sun and Ledell Wu and Xinggang Wang and Tiejun Huang and Xinlong Wang and Yue Cao},

year={2022},

eprint={2211.07636},

archivePrefix={arXiv},

primaryClass={cs.CV},

url={https://arxiv.org/abs/2211.07636},

}

5. @article{Fang_2024,

title={EVA-02: A visual representation for neon genesis},

volume={149},

ISSN={0262-8856},

url={http://dx.doi.org/10.1016/j.imavis.2024.105171},

DOI={10.1016/j.imavis.2024.105171},

journal={Image and Vision Computing},

publisher={Elsevier BV},

author={Fang, Yuxin and Sun, Quan and Wang, Xinggang and Huang, Tiejun and Wang, Xinlong and Cao, Yue},

year={2024},

month=Sept, pages={105171} }